

# TL02 Keras

## Índice

1. Introducción
2. Guías
3. API
4. Ejemplos
5. Un MLP sencillo para MNIST
6. Ejercicio: Fashion-MNIST

# 1 Introducción: [https://keras.io/getting\\_started](https://keras.io/getting_started)

**Keras 2:** librería Python de aprendizaje profundo basada en TensorFlow

**Keras 3:** versión reciente con multi-backend (JAX, TensorFlow y PyTorch)

**Creador y desarrollador principal:** François Chollet <https://fchollet.com>

**Documentación:** <https://keras.io>

**Github:** <https://github.com/keras-team>

**Prueba en Colab:** [https://keras.io/getting\\_started/intro\\_to\\_keras\\_for\\_engineers](https://keras.io/getting_started/intro_to_keras_for_engineers)

Tal vez sea necesario actualizar tensorflow y keras en una celda inicial de código:

```
In [ ]: !pip install tensorflow --upgrade --quiet
        !pip install keras --upgrade --quiet
```

**Backend benchmarks:** mejores resultados con Keras 3 y JAX o TF [https://keras.io/getting\\_started/benchmarks](https://keras.io/getting_started/benchmarks)

**Ecosistema Keras:** [https://keras.io/getting\\_started/ecosystem](https://keras.io/getting_started/ecosystem)

- **KerasTuner:** librería para el ajuste de hiper-parámetros
- **KerasNLP:** librería de procesamiento de lenguaje natural
- **KerasCV:** librería de visión por ordenador
- **AutoKeras:** sistema de AutoML basado en Keras

## 2 Guías: <https://keras.io/guides>

**Uso:** cuadernos jupyter fácilmente ejecutables en Colab

- The Functional API
- The Sequential model
- Making new layers & models via subclassing
- Training & evaluation with the built-in methods
- etc.

### **KerasTuner:**

- Getting started with KerasTuner
- Distributed hyperparameter tuning with KerasTuner
- etc.

### **KerasCV:**

- Use KerasCV to assemble object detection pipelines
- Use KerasCV to train powerful image classifiers
- etc.

### **KerasNLP:**

- Getting Started with KerasNLP
- Pretraining a Transformer from scratch with KerasNLP
- Uploading Models with KerasNLP

## 3 API: <https://keras.io/api>

**Models API:** Model class, Sequential class, Model training APIs, Saving & serialization

**Layers API:** Base Layer class, Layer activations, Layer weights, Core layers, Convolution layers, Pooling layers, etc.

**Callbacks API:** Base, ModelCheckpoint, EarlyStopping, LearningRateScheduler, ReduceLROnPlateau, etc.

**Ops API:** NumPy ops, NN ops, Linear algebra ops, Core ops, Image ops, FFT ops

**Optimizers:** SGD, RMSprop, Adam, AdamW, etc.

**Metrics:** Base class, Accuracy, Probabilistic, Regression, Image segmentation, etc.

**Losses:** Probabilistic losses, Regression losses, Hinge losses

**Data loading:** Image data, Timeseries data, Text data, Audio data

**Built-in datasets:** MNIST, CIFAR10, CIFAR100, IMBD, Reuters newswire, Fashion MNIST, California Housing price

**Misc.:** Mixed precision, Multi-device distribution, RNG API

**Utilities:** Model plotting, Structured data preprocessing, Tensor, Python & NumPy, Keras configuration

**Keras Applications:** EfficientNet, ResNet, DenseNet, InceptionV3, InceptionResNetV2, etc.

**KerasTuner:** HyperParameters, Tuners, Oracles, HyperModels, Errors

**KerasCV:** Layers, Models, Bounding box formats and utilities, Losses

**KerasNLP:** Pretrained Models, Models API, Tokenizers, Preprocessing Layers, Modeling Layers, Samplers, Metrics

## 4 Ejemplos: <https://keras.io/examples>

**Recomendados:** marcados con una estrella y V3 (Keras 3)

**CV:** clasificación de imágenes, segmentación de imágenes, subtitulado de imágenes, etc.

**NLP:** clasificación de texto, traducción automática, etc.

**Datos estructurados:** clasificación de datos estructurados, etc.

**Series temporales:** clasificación de series temporales, etc.

**Aprendizaje profundo generativo:** generación de imágenes, generación de texto, etc.

**Audio:** reconocimiento automático del habla, etc.

**Otros:** aprendizaje por refuerzo, grafos

**Recetas rápidas:** consejos de uso, etc.

# 5 Un MLP sencillo para MNIST

**Inicialización:** librerías y semilla para la generación de números aleatorios

```
In [ ]: import numpy as np
import matplotlib.pyplot as plt
import os; os.environ['TF_CPP_MIN_LOG_LEVEL'] = '2'
import keras
keras.utils.set_random_seed(23)
```

**Lectura de MNIST:**

```
In [ ]: (x_train, y_train), (x_test, y_test) = keras.datasets.mnist.load_data()
print(f'Lectura: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

input_dim = x_train.shape[1] * x_train.shape[2]
x_train = x_train.reshape(-1, input_dim).astype("float32")
x_test = x_test.reshape(-1, input_dim).astype("float32")
print(f'Reformato 1: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

x_train_max = np.max(x_train)
x_train /= x_train_max
x_test /= x_train_max
print(f'Normalización [0,1]: max = {x_train_max}')

num_classes = 10
y_train = keras.utils.to_categorical(y_train, num_classes)
y_test = keras.utils.to_categorical(y_test, num_classes)
print(f'Reformato 2: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

Lectura: train (60000, 28, 28) (60000,) test (10000, 28, 28) (10000,)
Reformato 1: train (60000, 784) (60000,) test (10000, 784) (10000,)
Normalización [0,1]: max = 255.0
Reformato 2: train (60000, 784) (60000, 10) test (10000, 784) (10000, 10)
```

**Definición del modelo:** MLP con una capa oculta de ReLUs y capa de salida softmax

```
In [ ]: M = keras.Sequential([keras.Input(shape=(input_dim,)),
                             keras.layers.Dense(800, activation='relu'),
                             keras.layers.Dense(num_classes, activation='softmax')])
M.summary()
```

**Model: "sequential"**

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 800)	628,000
dense_1 (Dense)	(None, 10)	8,010

**Total params:** 636,010 (2.43 MB)

**Trainable params:** 636,010 (2.43 MB)

**Non-trainable params:** 0 (0.00 B)

```
In [ ]: print(f'Número de parámetros de la capa oculta: {784*800 + 800}')
        print(f'Número de parámetros de la capa de salida: {800*10 + 10}')
```

Número de parámetros de la capa oculta: 628000  
Número de parámetros de la capa de salida: 8010


**Compilación del modelo:** definimos pérdida, optimizador y métrica

```
In [ ]: M.compile(loss="categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
```

**Entrenamiento:** definimos talla del batch y número de épocas (iteraciones)

```
In [ ]: H = M.fit(x_train, y_train, batch_size=16, epochs=10, verbose=0)
```

```
In [ ]: fig, axes = plt.subplots(1, 2, figsize=(9, 3.5))
xx = np.arange(1, len(H.history['loss'])+1)
ax = axes[0]; ax.grid(); ax.set_xlabel('epoch'); ax.set_ylabel('loss')
ax.set_xticks(xx); ax.plot(xx, H.history['loss'], color='b', marker='s')
ax = axes[1]; ax.grid(); ax.set_xlabel('epoch'); ax.set_ylabel('accuracy')
ax.set_xticks(xx); ax.plot(xx, H.history['accuracy'], color='b', marker='s');
```



**Evaluación:**

```
In [ ]: score = M.evaluate(x_test, y_test, verbose=0)
print(f'Loss: {score[0]:.4}\nPrecisión: {score[1]:.1%}')
```

Loss: 0.1051  
Precisión: 98.1%



# 6 Ejercicio: Fashion-MNIST

**Ejercicio:** realiza un experimento similar al de MNIST con Fashion-MNIST

**Inicialización:** librerías y semilla para la generación de números aleatorios

```
In [ ]: import numpy as np
import matplotlib.pyplot as plt
import os; os.environ['TF_CPP_MIN_LOG_LEVEL'] = '2'
import keras
keras.utils.set_random_seed(23)
```

**Lectura de Fashion-MNIST:**

```
In [ ]: (x_train, y_train), (x_test, y_test) = keras.datasets.fashion_mnist.load_data()
print(f'Lectura: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

input_dim = x_train.shape[1] * x_train.shape[2]
x_train = x_train.reshape(-1, input_dim).astype("float32")
x_test = x_test.reshape(-1, input_dim).astype("float32")
print(f'Reformato 1: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

x_train_max = np.max(x_train)
x_train /= x_train_max
x_test /= x_train_max
print(f'Normalización [0,1]: max = {x_train_max}')

num_classes = 10
y_train = keras.utils.to_categorical(y_train, num_classes)
y_test = keras.utils.to_categorical(y_test, num_classes)
print(f'Reformato 2: train {x_train.shape} {y_train.shape} test {x_test.shape} {y_test.shape}')

Lectura: train (60000, 28, 28) (60000,) test (10000, 28, 28) (10000,)
Reformato 1: train (60000, 784) (60000,) test (10000, 784) (10000,)
Normalización [0,1]: max = 255.0
Reformato 2: train (60000, 784) (60000, 10) test (10000, 784) (10000, 10)
```

**Definición del modelo:** MLP con una capa oculta de ReLUs y capa de salida softmax

```
In [ ]: M = keras.Sequential([keras.Input(shape=(input_dim,)),
    keras.layers.Dense(800, activation='relu'),
    keras.layers.Dense(num_classes, activation='softmax')])
M.summary()
```

**Model: "sequential"**

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 800)	628,000
dense_1 (Dense)	(None, 10)	8,010

**Total params:** 636,010 (2.43 MB)

**Trainable params:** 636,010 (2.43 MB)

**Non-trainable params:** 0 (0.00 B)

```
In [ ]: print(f'Número de parámetros de la capa oculta: {784*800 + 800}')
print(f'Número de parámetros de la capa de salida: {800*10 + 10}')
```

Número de parámetros de la capa oculta: 628000  
Número de parámetros de la capa de salida: 8010


**Compilación del modelo:** definimos pérdida, optimizador y métrica

```
In [ ]: M.compile(loss="categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
```

**Entrenamiento:** definimos talla del batch y número de épocas (iteraciones)

```
In [ ]: H = M.fit(x_train, y_train, batch_size=16, epochs=20, verbose=0)
```

```
In [ ]: fig, axes = plt.subplots(1, 2, figsize=(10, 3.5))
xx = np.arange(1, len(H.history['loss'])+1)
ax = axes[0]; ax.grid(); ax.set_xlabel('epoch'); ax.set_ylabel('loss')
ax.plot(xx, H.history['loss'], color='b', marker='s')
ax = axes[1]; ax.grid(); ax.set_xlabel('epoch'); ax.set_ylabel('accuracy')
ax.plot(xx, H.history['accuracy'], color='b', marker='s');
```



**Evaluación:**

```
In [ ]: score = M.evaluate(x_test, y_test, verbose=0)
print(f'Loss: {score[0]:.4}\nPrecisión: {score[1]:.1%}')
```

Loss: 0.4734  
Precisión: 88.0%